مقدمة في المشهد السيبراني والدور الحيوي لأنظمة كشف التسلل

يتميز العصر الرقمي الحديث بتوسع غير مسبوق في حجم وتنوع البيانات، وهي ظاهرة مدفوعة بالنضج السريع لإنترنت الأشياء (IoT)، واتصالات الجيل الخامس (5G)، وهياكل السحابة المتعددة [1، 2]. ومع تزايد لامركزية البنى التحتية للشبكات، اتسعت مساحة الهجوم المحتملة بشكل كبير، مما استلزم الانتقال من الدفاعات المحيطية الثابتة إلى أنظمة مراقبة ذكية وديناميكية. ويُعد الأمن السيبراني في جوهره ممارسة لضمان السرية والنزاهة والتوافر (CIA) لهذه الأصول الرقمية.[1] وضمن هذا الإطار، تعمل أنظمة كشف التسلل (IDS) كعضو حسي حيوي للشبكة، مصمم لتحليل أنماط حركة المرور وسلوكيات النظام لتحديد الانحرافات التي تشير إلى نوايا خبيثة [1، 4].

لا يمكن المبالغة في أهمية IDS في بيئات المؤسسات الحديثة؛ فمع توقع وصول سوق أمن إنترنت الأشياء العالمي إلى حوالي 20.77 مليار دولار بحلول عام 2025، أصبح الطلب على حلول أمنية قابلة للتوسع والتكيف في أعلى مستوياته.[2] الدفاعات التقليدية التي تعتمد على الإشراف اليدوي والمنطق الحتمي، أصبحت مشلولة أمام مشكلة "البيانات الضخمة"، حيث يجعل حجم سجلات الشبكة وتدفقات حركة المرور الفرز البشري وحده غير ممكن عملياً.[3] علاوة على ذلك، فإن ظهور التهديدات المستمرة المتقدمة (APTs) والبرمجيات الخبيثة متعددة الأشكال يتطلب مستوى من التعرف على الأنماط يتجاوز قدرات المرشحات القياسية القائمة على القواعد [4، 6].

تتمثل إحدى العقبات الأكثر استمراراً في هذا المجال في اختلال التوازن المتأصل في بيانات حركة مرور الشبكة. ففي بيئة المؤسسات النموذجية، تشكل الأنشطة الحميدة أكثر من 99% من جميع الأحداث، مما يجعل اكتشاف الهجمات النادرة بمثابة البحث عن "إبرة في كومة قش" [7، 8]. هذا الاختلال، إلى جانب متطلبات السرعة العالية لشبكات 5G وأنظمة التحكم الصناعية، يخلق بيئة معقدة حيث يجب أن يحافظ نظام IDS على دقة مثالية تقريباً مع العمل بحد أدنى من التأخير [2، 9]. وقد ظهرت أنظمة كشف التسلل القائمة على الذكاء الاصطناعي كحل محوري لهذه التحديات، حيث تستفيد من خوارزميات التعلم الآلي (ML) والتعلم العميق (DL) للتعلم والتكيف والاستجابة تلقائياً لمشهد التهديدات المتطور في الوقت الفعلي [1، 10].

بيان المشكلة: القيود الفنية للكشف التقليدي والحاجة إلى الذكاء

الهدف الأساسي لكشف التسلل هو التصنيف الدقيق لأحداث الشبكة في ظل ظروف تطاير البيانات الشديدة. ومع ذلك، تواجه الأساليب التأسيسية للعقود السابقة أزمة فائدة. تهيمن الأنظمة التقليدية إلى حد كبير على أنظمة كشف التسلل القائمة على التوقيع (SIDS)، والتي تعمل عن طريق مطابقة حركة المرور الملحوظة مع قاعدة بيانات محددة مسبقاً لأنماط الهجمات المعروفة [11، 12]. وبينما تعد SIDS فعالة للغاية في تحديد التهديدات المعترف بها مع معدل منخفض من الإيجابيات الكاذبة، إلا أنها بطبيعتها تفاعلية؛ فهي "عمياء" تماماً عن أي نشاط ليس لديها توقيع له بعد، وهو قيد يستغله المهاجمون من خلال هجمات يوم الصفر (Zero-day) [13، 14].

تتجلى شدة مشكلة يوم الصفر في الأبحاث التي تظهر أن هجوم يوم الصفر النموذجي يظل غير مكتشف لمدة 312 يوماً في المتوسط.[4] خلال هذه النافذة، يتم تجاوز الآليات الأمنية التقليدية بفعالية، مما يؤدي غالباً إلى اختراقات بيانات بمتوسط تكلفة يبلغ 1.2 مليون دولار لكل حادثة.[4] وبالإضافة إلى الفشل في اكتشاف التهديدات غير المعروفة، تعاني الأنظمة التقليدية من عدة اختناقات تشغيلية:

معضلة الإيجابيات الكاذبة والسلبيات الكاذبة

غالباً ما تولد الأنظمة القائمة على القواعد حجماً هائلاً من التنبيهات، والعديد منها عبارة عن إيجابيات كاذبة (FPs) ناتجة عن سلوك حميد ولكنه غير معتاد، مثل تحديث برمجيات كبير [6، 15]. يؤدي هذا إلى "إرهاق التنبيهات"، حيث يصبح محللو الأمن أقل حساسية للتحذيرات، مما قد يؤدي إلى التغاضي عن اختراق حقيقي (سلبي كاذب أو FN) مدفون داخل الضوضاء [15، 16]. تهدف النماذج المدفوعة بالذكاء الاصطناعي إلى تخفيف ذلك من خلال وضع خط أساس سلوكي أكثر دقة، مما يسمح بدقة أعلى في الكشف [6، 16].

متطلبات التوسع وزمن الاستجابة في الوقت الفعلي

تعالج الشبكات الحديثة ملايين الحزم في الثانية. تتطلب أنظمة SIDS فحصاً حسابياً مقابل آلاف القواعد لكل حزمة، مما قد يسبب تدهوراً كبيراً في الأداء.[5] ومع زيادة سرعات تسريب البيانات - حيث قادرة أسرع الهجمات الحديثة على سرقة البيانات في غضون 72 دقيقة - يصبح التأخير الذي تسببه المعالجة التقليدية خطراً أمنياً حرجاً [5، 9]. لذلك، يجب تحسين نماذج الذكاء الاصطناعي من حيث السرعة، مع

موازنة تعقيد هياكل التعلم العميق مع الحاجة إلى الاستدلال في أجزاء من الثانية [9، 17].

جدول 1: مقارنة بين قيود SIDS وحلول الذكاء الاصطناعي

فئة المشكلة	قيود الأنظمة القائمة على التوقيع (SIDS)	حلول IDS القائمة على الذكاء الاصطناعي
التهديدات غير المعروفة	غير فعالة ضد هجمات يوم الصفر.	كشف الشذوذ يحدد الانحرافات الجديدة.
تكتيكات المراوغة	يتم تجاوزها بالبرمجيات متعددة الأشكال.	تحلل النية السلوكية بدلاً من الصيغة.
إدارة التنبيهات	معدل إيجابيات كاذبة مرتفع/إرهاق التنبيهات.	وضع الخطوط الأساسية السلوكية يقلل الضوضاء.
سرعة الاستجابة	تفاعلية (تحديث التوقيع بعد وقوع الحدث).	استباقية وكشف في الوقت الفعلي.
حجم البيانات	اختناقات في الشبكات عالية السرعة.	قابلة للتوسع من خلال تحليل الميزات القائمة على التدفق.

[5، 12، 15، 17، 18]

تصنيف أنظمة كشف التسلل: البنى والمنهجيات

يتم تصنيف أنظمة كشف التسلل بناءً على منطق الكشف الخاص بها وتوزيعها المادي أو المنطقي داخل الشبكة.

نظام كشف التسلل القائم على التوقيع (SIDS)

تعمل هذه الأنظمة كـ "كتيب رقمي" للمهاجمين المعروفين. تستخدم مطابقة السلاسل وتحليل رأس الحزمة لتحديد تسلسلات معينة من البايتات المرتبطة بمتغيرات البرامج الضارة، أو محاولات حقن SQL [11، 12]. وتعد أدوات مثل Snort و Suricata معايير صناعية في هذه الفئة. ميزتها الأساسية هي السرعة والموثوقية للتهديدات المعروفة، لكن طبيعتها الثابتة تجعلها غير فعالة ضد الحمولات المتطورة.[5]

نظام كشف التسلل القائم على الشذوذ (AIDS)

تمثل هذه الأنظمة الجناح السلوكي لكشف التسلل. باستخدام التعلم الآلي لإنشاء خط أساس للسلوك "الطبيعي" للنظام، يمكن لهذه الأنظمة الإبلاغ عن أي خروج ملحوظ كتهديد محتمل [11، 19]. وفي حين أن AIDS متفوقة في اكتشاف هجمات يوم الصفر، إلا أنها عرضة

لمعدلات أعلى من الإيجابيات الكاذبة لأن "غير المعتاد" لا يعني دائماً "خبيثاً" [1، 15].

أنظمة كشف التسلل الهجينة

المعيار الذهبي الحديث هو النهج الهجين الذي يدمج SIDS و AIDS. في هذه الأطر، يتعامل محرك قائم على التوقيع مع الهجمات المعروفة بدقة عالية، بينما يراقب محرك الشذوذ القائم على الذكاء الاصطناعي الانحرافات الدقيقة [3، 20]. يضمن هذا الكشف ثنائي المراحل استخدام الموارد الأمنية بكفاءة [20، 21].

الأنظمة المستندة إلى الشبكة (NIDS) مقابل المستندة إلى المضيف (HIDS)

تقوم NIDS بمراقبة حركة المرور أثناء عبورها للشبكة، وهي فعالة في اكتشاف الهجمات الواسعة مثل DDoS [22، 23]. أما HIDS، فتقيم على خوادم أو نقاط نهاية فردية، وتراقب الأنشطة الداخلية للنظام مثل سجلات الملفات [9، 23]. توفر NIDS رؤية واسعة، بينما توفر HIDS العمق اللازم لاكتشاف الهجمات الداخلية [5، 9].

جدول 2: مزايا وقيود أنواع IDS

النوع	الميزة	القيد
قائم على التوقيع	دقة عالية للهجمات المعروفة؛ عبء منخفض.	غير فعال ضد يوم الصفر؛ يتطلب تحديثات متكررة.
قائم على الشذوذ	يكتشف التهديدات غير المعروفة والمتطورة.	معدل إيجابيات كاذبة أعلى؛ مكلف حسابياً.
هجين	يجمع بين سرعة SIDS وقابلية AIDS للتكيف.	معقد في الدمج والإدارة.
مستند إلى الشبكة	رؤية واسعة؛ لا يؤثر على أداء المضيف.	لا يرى حركة المرور المشفرة أو إجراءات المضيف الداخلية.
مستند إلى المضيف	رؤية عميقة لنشاط مستوى النظام.	يستهلك موارد المضيف؛ رؤية محدودة للشبكة.

[5، 9، 11، 12، 17، 23]

الهندسة المتكاملة لأنظمة IDS القائمة على الذكاء الاصطناعي

يتبع بناء نظام IDS القائم على الذكاء الاصطناعي خط أنابيب هندسي منظم للغاية:

جمع البيانات واستيعابها

تبدأ العملية بالحصول على البيانات الخام من مصادر متنوعة مثل أجهزة التوجيه وسجلات الخوادم.[6] يفرق الباحثون بين نوعين من البيانات:

- **التقاط الحزم بالكامل (Packet-Based):** يتضمن التقاط الحزمة كاملة. يوفر أقصى قدر من الرؤية ولكنه يستهلك موارد هائلة ويواجه صعوبات مع التشفير [22، 26].
- **التقاط التدفق (Flow-Based):** يتضمن تجميع الحزم في "تدفقات" أو جلسات (مثل بيانات NetFlow). يتضمن سجل التدفق عادةً عناوين IP، والمنافذ، والبروتوكول، وإجمالي البايتات [21، 22]. تحليل التدفق أكثر قابلية للتوسع بشكل كبير.[7]

المعالجة المسبقة وتحويل البيانات

نادراً ما تكون سجلات الشبكة الخام بتنسيق مناسب للتعلم الآلي. تتضمن هذه المرحلة:

1. **التنظيف:** التعامل مع القيم المفقودة وإزالة السجلات المكررة [3، 27، 28].
2. **التقييس/التحجيم (Normalization):** نظراً لأن ميزات الشبكة تختلف في الحجم (مثل عدد الحزم مقابل المدة)، يجب قياسها إلى نطاق قياسي، عادةً $$ [28، 29].
3. **الترميز (Encoding):** يجب تحويل البيانات الفئوية، مثل نوع البروتوكول (TCP, UDP)، إلى قيم عددية من خلال تقنيات مثل الترميز الأحادي (One-Hot Encoding) [3، 28، 30].

هندسة الميزات واختيارها

تتضمن اختيار السمات الأكثر صلة وإنشاء سمات جديدة تلتقط الخصائص السلوكية للهجوم [31، 32]. على سبيل المثال، "50 حزمة مرسلة إلى منافذ مختلفة في غضون ثانيتين" هو مؤشر واضح على مسح المنافذ [33، 34].

تدريب النماذج وطبقة الكشف

في هذه المرحلة، يتم استخدام البيانات المعالجة لتدريب نموذج الذكاء الاصطناعي لتعلم الأنماط الأساسية لكل من حركة المرور الحميدة والخبيثة [4، 32].

نماذج التعلم الآلي والتعلم العميق المستخدمة في IDS

التعلم الآلي التقليدي (ML)

- **الغابة العشوائية (Random Forest):** تبني أشجار قرار متعددة وتدمجها للحصول على تنبؤ أكثر دقة واستقراراً. أظهرت الدراسات أنها تحقق دقة تقترب من 99% في البيانات المتوازنة [11، 15، 35].
- **آلات المتجهات الداعمة (SVM):** تجد المستوى الفائق الأمثل الذي يفصل بين الفئات بأكبر هامش ممكن [15، 17].
- **الجار الأقرب (KNN):** يصنف سجل حركة المرور بناءً على فئة جيرانه الأكثر تشابهاً في مساحة الميزات [15، 37].

نماذج التعلم العميق (DL)

- **الشبكات العصبية الالتفافية (CNN):** ممتازة في اكتشاف الأنماط المحلية داخل الحزمة أو التدفق [15، 17].
- **الشبكات العصبية المتكررة (RNN) و LSTM:** مصممة لمعالجة البيانات المتسلسلة زمنياً، مما يسمح لها باكتشاف الهجمات

البطيئة التي تحدث على مدار دقائق أو ساعات [17، 21].
- **المشفرات التلقائية (Autoencoders)**: نماذج غير خاضعة للإشراف تستخدم لكشف الشذوذ. تتعلم ضغط البيانات الطبيعية وإعادة بنائها. يؤدي الفشل في إعادة بناء هجوم (خطأ إعادة بناء عالٍ) إلى إطلاق تنبيه [19، 38، 39].

مقاييس تقييم الأداء: التنقل في مفارقة الاختلال

في سياق كشف التسلل، يمكن أن تكون درجة "الدقة" البسيطة مضللة بشكل خطير. لذلك، يعتمد المجتمع السيبراني على مقاييس أكثر دقة:

- **الدقة (Accuracy)**: النسبة المئوية لجميع التنبؤات الصحيحة.

$$\frac{TP + TN}{TP + TN + FP + FN} = Accuracy$$

[7، 41]
- **الدقة التحديدية (Precision)**: نسبة التنبيهات التي تم الإبلاغ عنها وكانت خبيثة بالفعل.

$$\frac{TP}{TP + FP} = Precision$$

[7، 41]
- **الاستدعاء (Recall)**: نسبة الهجمات الفعلية التي حددها النظام بشكل صحيح. هذا هو المقياس الأكثر حرجاً في الأمن [7، 41، 42].

$$\frac{TP}{TP + FN} = Recall$$

[7، 41]
- **مقياس F1-Score**: المتوسط التوافقي للدقة والاستدعاء. هو أفضل مقياس منفرد للبيانات غير المتوازنة.

$$\frac{Precision \times Recall}{Precision + Recall} \times 2 = F1$$

[7، 41، 43]

تحليل حالة الفن (State of the Art)

تشير الأبحاث الحديثة إلى تفوق النماذج الهجينة:

- **الهجين CapsNet + BiLSTM**: حقق دقة تقارب 99% على مجموعة بيانات CIC-IDS2017 [3، 20].
- **الغابة العشوائية مع تقليل الميزات (RF-RFE)**: حقق دقة 99.9% على CSE-CIC-IDS2018 مع كفاءة حسابية عالية جداً.[8]

التحديات والحل المقترح (Sentinel-AI)

للمؤسسات التي تسعى لتنفيذ نظام IDS متطور، نوصي بهيكل "Sentinel-AI" المكون من عدة مراحل:

1. **طبقة الحصول على البيانات**: استخدام **Scapy** لالتقاط الحزم في الوقت الفعلي و **CICFlowMeter** لاستخراج الميزات السلوكية [23، 47، 48].

2. **خط أنابيب المعالجة:** استخدام تقنية **ADASYN** لمعالجة اختلال توازن البيانات [44، 49].
3. **محرك كشف ثنائي المرحلة:**
   - **المرحلة 1:** مصنف **Random Forest** محسّن ليعمل كمرشح عالي السرعة.
   - **المرحلة 2:** **Denoising Autoencoder** للتحقيق في الحركة المشبوهة باستخدام "ناقل خطأ إعادة البناء" (Reconstruction Error Vector) لتحديد الميزة المحددة التي تسببت في الشذوذ [39، 50].
4. **قابلية التفسير:** دمج **SHAP** لتزويد المحللين بتمثيل مرئي للميزات التي ساهمت في التنبيه [2، 3].

الخاتمة: الضرورة الاستراتيجية للذكاء الاصطناعي

مع انتقال الهجمات السيبرانية إلى سرعة الآلة، لم يعد الانتقال إلى أنظمة IDS القائمة على الذكاء الاصطناعي خياراً، بل ضرورة استراتيجية. إن النجاح في العقد القادم سيعتمد على القدرة على نشر ذكاء اصطناعي "خفيف الوزن" عند حافة الشبكة، والتحكم في اختلال توازن البيانات، وتطوير نماذج قابلة للتفسير تمكن المحللين البشر بدلاً من إغراقهم بالضوضاء [3، 5، 9].

Works cited

1. (PDF) Improving Intrusion Detection with Hybrid Deep Learning Models: A Study on CIC-IDS2017, UNSW-NB15, and KDD CUP 99 - ResearchGate, accessed April 7, 2026, https://www.researchgate.net/publication/389144460_Improving_Intrusion_Detection_with_Hybrid_Deep_Learning_Models_A_Study_on_CIC-IDS2017_UNSW-NB15_and_KDD_CUP_99
2. AI-Enabled IoT Intrusion Detection: Unified Conceptual Framework and Research Roadmap, accessed April 7, 2026, https://www.mdpi.com/2504-4990/7/4/115
3. AI threat detection: 7 methods across 6 security domains - Vectra AI, accessed April 7, 2026, https://www.vectra.ai/topics/ai-threat-detection
4. A Survey of Machine Learning-Based Zero-Day Attack Detection: Challenges and Future Directions - PMC, accessed April 7, 2026, https://pmc.ncbi.nlm.nih.gov/articles/PMC9890381/
5. Overview on Intrusion Detection Systems for Computers Networking Security - MDPI, accessed April 7, 2026, https://www.mdpi.com/2073-431X/14/3/87
6. What Is a Machine Learning Pipeline? - Snowflake, accessed April 7, 2026, https://www.snowflake.com/en/fundamentals/building-effective-machine-learning-pipelines/
7. Packet Vs. Flow: A Look at Network Traffic Analysis Techniques - LiveAction, accessed April 7, 2026, https://www.liveaction.com/resources/solution-briefs/packet-vs-flow-a-look-at-network-traffic-analysis-techniques/
8. Optimization of predictive performance of intrusion detection system using hybrid ensemble model for secure systems - PMC, accessed April 7, 2026, https://pmc.ncbi.nlm.nih.gov/articles/PMC10496009/