CyberSentinel AI Challenge

Intelligence Artificielle pour la Détection Avancée des Intrusions Réseau

A Machine Learning Approach for Intrusion Detection Systems (IDS)

Ce challenge propose de développer des modèles d'**Intelligence Artificielle** capables d'identifier, analyser et classifier des comportements malveillants au sein de flux réseau complexes.
En s'appuyant sur le dataset de référence **KDD Cup 1999**, les participants devront concevoir des solutions robustes permettant de distinguer efficacement le trafic légitime des différentes catégories d'attaques (**DoS, Probe, R2L, U2R**), tout en minimisant les faux positifs.

"From Raw Network Traffic to Intelligent Threat Detection"

Mini Hackathon IA & Cybersécurité

Université de Monastir
Institut Supérieur d'Informatique de Mahdia (ISIMa)

Objectif du Challenge : Sélectionner les équipes les plus performantes afin de représenter l'ISIMa lors du Hackathon Intra-Universitaire organisé par le Palais des sciences en collaboration avec l'Université de Monastir.

1. Contexte et Problématique

La cybersécurité est devenue un pilier fondamental des infrastructures numériques modernes, en raison de la transformation digitale accélérée et de l'interconnexion massive des systèmes. Cette évolution s'accompagne d'une augmentation significative de la surface d'attaque, rendant les réseaux informatiques particulièrement vulnérables à des menaces de plus en plus sophistiquées et évolutives [1].

Les **Systèmes de Détection d'Intrusion** (*Intrusion Detection Systems* – IDS) constituent une ligne de défense essentielle pour identifier les comportements anormaux ou malveillants dans le trafic réseau. Ces systèmes peuvent être classés en deux grandes catégories : les IDS basés sur les signatures et ceux basés sur les anomalies. Cependant, les approches traditionnelles présentent des limites importantes face à des attaques inconnues, polymorphes ou distribuées [2].

Dans ce contexte, l'intégration des techniques d'**Intelligence Artificielle**, et plus particulièrement du **Machine Learning**, a permis d'améliorer significativement les capacités de détection en introduisant des modèles capables d'apprendre des représentations complexes du trafic réseau. Ces approches reposent généralement sur une chaîne de traitement structurée, allant de la capture du trafic brut jusqu'à la prise de décision automatisée, comme illustré dans la Figure 1.

Néanmoins, malgré ces avancées, plusieurs défis majeurs persistent :

- **Volume et vélocité des données :** Les réseaux modernes génèrent des flux massifs nécessitant des traitements quasi temps réel.
- **Hétérogénéité des attaques :** Les cyberattaques (DoS, Probe, R2L, U2R) présentent des signatures et comportements variés.
- **Déséquilibre des classes :** Les données sont fortement biaisées vers le trafic normal, compliquant l'apprentissage supervisé.
- **Capacité de généralisation :** Les modèles doivent détecter des attaques inconnues ou émergentes (zero-day).

Dans ce cadre, le dataset **KDD Cup 1999** s'impose comme un benchmark historique pour l'évaluation des approches de détection d'intrusion basées sur le Machine Learning. Bien qu'il présente certaines limitations (redondance, données simulées), il reste largement utilisé pour comparer les performances des modèles dans un cadre contrôlé [3].

L'enjeu scientifique central consiste à concevoir des modèles capables d'extraire des représentations discriminantes du trafic réseau, afin de distinguer efficacement les comportements normaux des activités malveillantes dans des environnements dynamiques et incertains.

2. Objectifs du Challenge

L'objectif de ce challenge s'inscrit dans le cadre de la conception de systèmes intelligents capables de détecter et classifier des comportements anormaux dans des environnements réseau complexes.

Objectif principal

L'objectif principal consiste à développer un modèle d'apprentissage automatique permettant de réaliser une **classification supervisée du trafic réseau**, en distinguant efficacement :

- le **trafic normal**
- les différentes **catégories d'attaques** (DoS, Probe, R2L, U2R)

D'un point de vue formel, il s'agit d'apprendre une fonction de décision :

$$f : \mathcal{X} \to \mathcal{Y}$$

où $\mathcal{X}$ représente l'espace des caractéristiques extraites du trafic réseau, et $\mathcal{Y}$ l'ensemble des classes cibles.

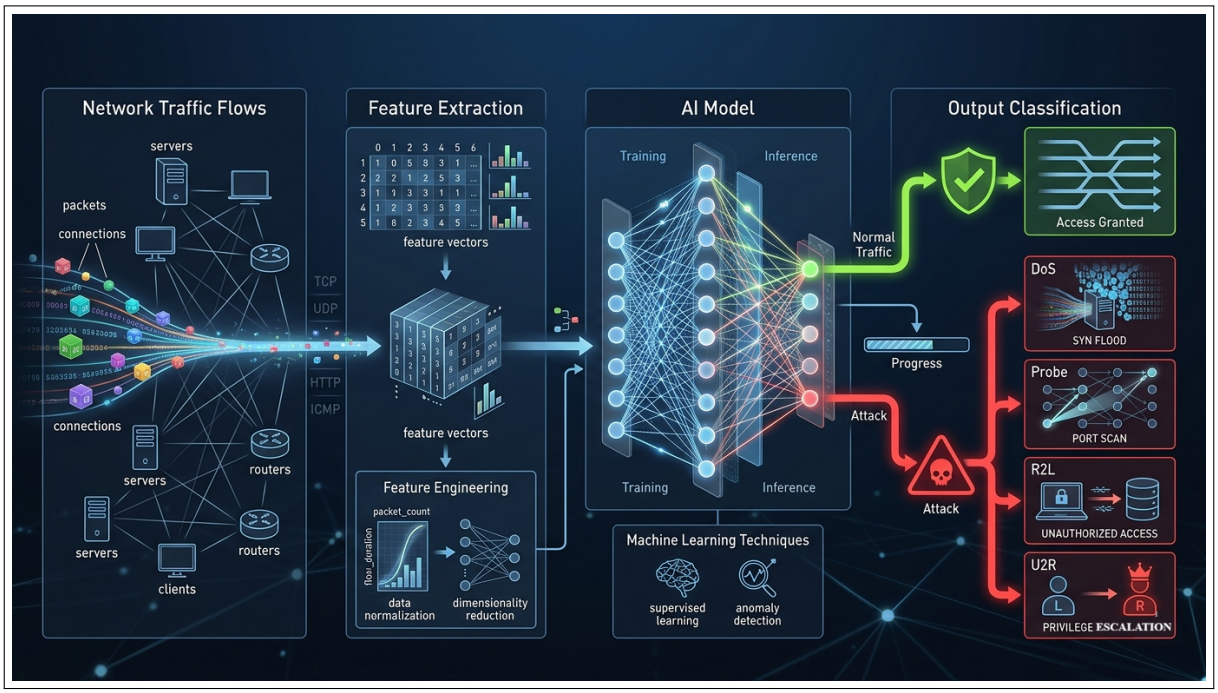


FIGURE 1 – Architecture générale d'un système de détection d'intrusion basé sur l'Intelligence Artificielle. Le processus comprend plusieurs étapes : (1) capture des flux réseau (paquets, connexions), (2) extraction et ingénierie des caractéristiques (feature extraction & feature engineering), (3) apprentissage d'un modèle de Machine Learning ou Deep Learning, et (4) classification du trafic en comportements normaux ou malveillants. Les attaques sont catégorisées en différentes classes, notamment DoS (Denial of Service), Probe (scan réseau), R2L (Remote to Local) et U2R (User to Root), illustrant la diversité et la complexité des menaces traitées.

Objectifs secondaires

Afin de garantir la pertinence et la robustesse des solutions proposées, plusieurs objectifs complémentaires sont considérés :

- **Classification multi-classes :** Concevoir un modèle capable de discriminer finement plusieurs types d'attaques, au-delà d'une simple détection binaire.
- **Réduction des faux positifs :** Minimiser le taux de fausses alertes afin d'améliorer la fiabilité opérationnelle du système IDS.
- **Gestion du déséquilibre des classes :** Développer des approches robustes face à la distribution fortement déséquilibrée des données (trafic normal dominant).
- **Capacité de généralisation :** Assurer la détection d'attaques inconnues ou émergentes (scénarios de type *zero-day*).
- **Optimisation des performances :** Maximiser les métriques d'évaluation (Accuracy, F1-score, Recall, etc.) tout en garantissant une complexité computationnelle maîtrisée.

Ce challenge vise à rapprocher les participants des problématiques réelles de cybersécurité, en les confrontant à des contraintes de performance, de robustesse et de généralisabilité propres aux systèmes de détection d'intrusion modernes.

3. Description du Dataset

Le dataset **KDD Cup 1999** constitue l'un des jeux de données de référence les plus utilisés dans la littérature pour l'évaluation des systèmes de détection d'intrusion basés sur le Machine Learning. Il a été élaboré dans le cadre du programme **DARPA Intrusion Detection Evaluation** mené par

le *MIT Lincoln Laboratory*, dans l'objectif de simuler des environnements réseau réalistes intégrant à la fois du trafic normal et des activités malveillantes [1]. [1]

Origine et Contexte

— Programme DARPA Intrusion Detection Evaluation
— Développé par le MIT Lincoln Laboratory
— Utilisé dans la compétition internationale KDD Cup 1999

Caractéristiques Générales

Le dataset présente les caractéristiques suivantes :
— Environ **4.9 millions d'instances** (version complète)
— **41 variables descriptives** et une variable cible (label)
— Données issues de **simulations contrôlées de trafic réseau**
— Présence de variables **numériques et catégorielles**

Chaque instance représente une connexion réseau décrite par un ensemble de caractéristiques permettant de modéliser le comportement du trafic à différents niveaux (paquet, session, agrégation temporelle).

Typologie des Attaques

Les attaques sont organisées en quatre grandes catégories :
— **DoS (Denial of Service)** : Attaques visant à rendre un service indisponible en saturant ses ressources (ex : *SYN flood*).
— **Probe** : Activités de reconnaissance destinées à explorer la topologie du réseau et identifier des vulnérabilités (ex : *port scanning*).
— **R2L (Remote to Local)** : Accès non autorisé obtenu à partir d'une machine distante (ex : attaques par dictionnaire).
— **U2R (User to Root)** : Escalade de privilèges permettant d'obtenir des droits administrateur à partir d'un compte utilisateur.

Catégorisation des Features

Les 41 variables du dataset peuvent être regroupées en trois catégories principales :
— **Basic Features** : informations extraites directement des connexions réseau (durée, protocole, etc.)
— **Content Features** : caractéristiques liées au contenu des paquets et aux comportements utilisateurs
— **Traffic Features** : statistiques calculées sur des fenêtres temporelles

1. `http://kdd.ics.uci.edu/databases/kddcup99/kddcup99.html`

Exemples de Features

Feature	Type	Description
duration	Numérique	Durée de la connexion
protocol_type	Catégoriel	Type de protocole (TCP, UDP, ICMP)
service	Catégoriel	Service réseau ciblé (HTTP, FTP, etc.)
src_bytes	Numérique	Volume de données envoyées par la source
dst_bytes	Numérique	Volume de données reçues
count	Numérique	Nombre de connexions similaires

Tableau Synthétique des Catégories

Catégorie	Nombre	Description
Basic Features	9	Informations de base sur la connexion
Content Features	13	Analyse du contenu et des comportements
Traffic Features	19	Statistiques temporelles et agrégées

Malgré sa popularité, le dataset KDD Cup 1999 présente certaines limitations structurelles, notamment une forte redondance des instances et un déséquilibre significatif entre les classes. Ces aspects peuvent introduire des biais dans l'apprentissage et fausser l'évaluation des performances des modèles [2].

L'utilisation de ce dataset dans le cadre du présent challenge vise à offrir un cadre expérimental standardisé permettant la comparaison rigoureuse des approches de détection d'intrusion.

7. Protocole d'Évaluation

L'évaluation des modèles proposés dans le cadre de ce challenge repose sur un protocole expérimental rigoureux, inspiré des pratiques standards en apprentissage automatique appliqué à la cybersécurité.

Cadre Expérimental

Les participants devront entraîner et valider leurs modèles selon une stratégie de séparation des données garantissant une évaluation fiable :

— Partitionnement des données en ensembles **apprentissage** et **test**
— Possibilité d'utiliser une **validation croisée** pour optimiser les hyperparamètres
— Évaluation finale réalisée sur un **jeu de test non vu**

L'objectif est d'évaluer la capacité de généralisation des modèles face à des données inconnues, condition essentielle dans les systèmes IDS réels.

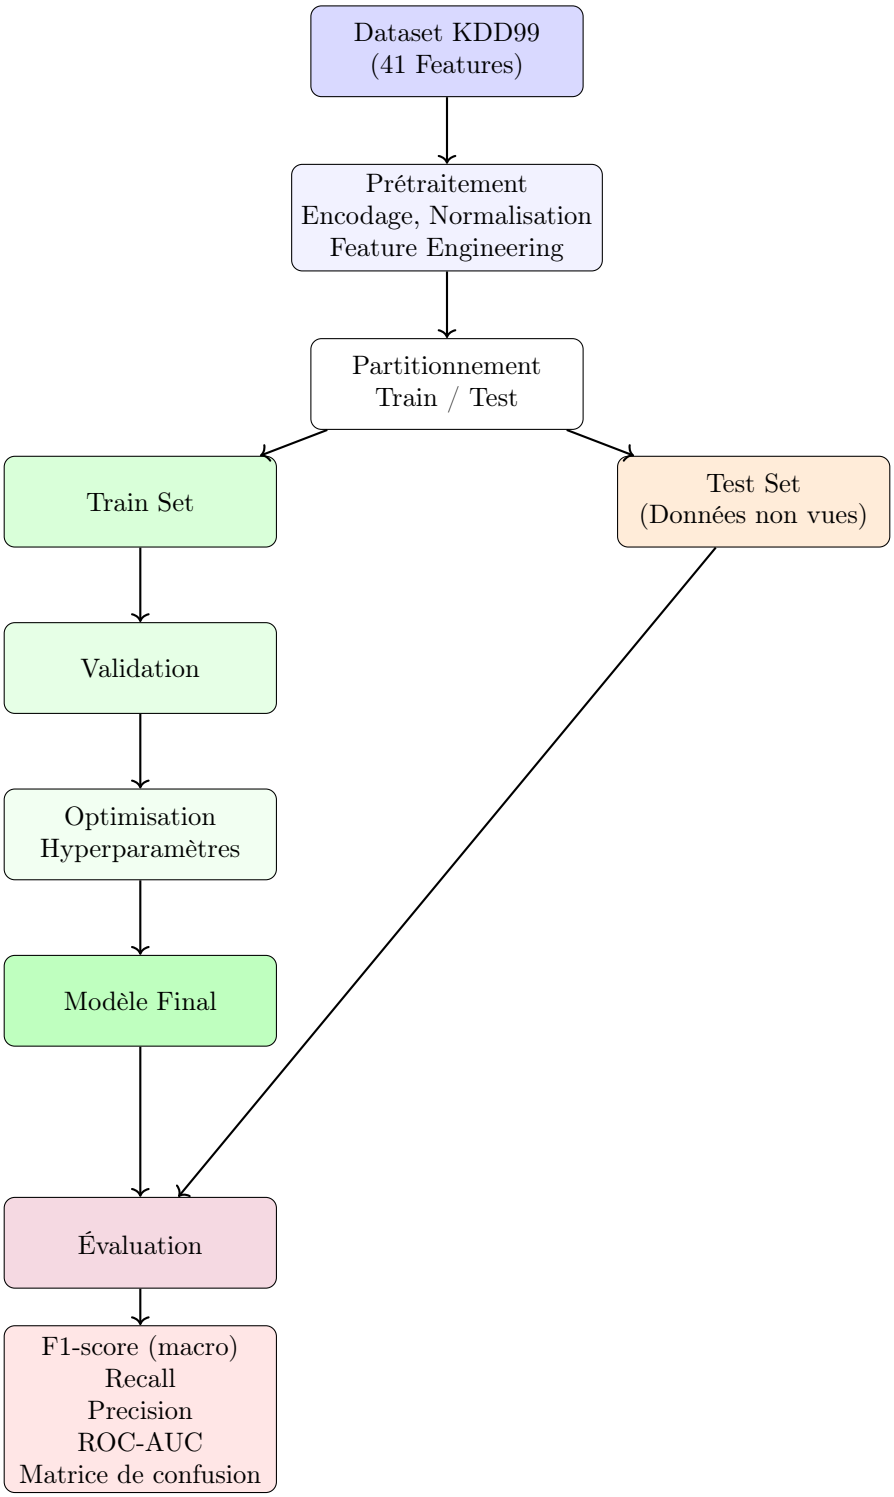


FIGURE 2 – Pipeline expérimental rigoureux pour l'évaluation d'un système de détection d'intrusion basé sur le Machine Learning. Le dataset est partitionné en ensembles d'apprentissage et de test afin d'éviter toute fuite d'information (data leakage). Le modèle est entraîné exclusivement sur les données d'apprentissage, en intégrant une validation croisée et une optimisation des hyperparamètres pour la sélection du modèle. L'évaluation finale est réalisée sur un ensemble de test strictement indépendant, garantissant une estimation fiable des performances de généralisation. Les métriques utilisées incluent le F1-score macro, le Recall, la Precision et l'aire sous la courbe ROC (AUC), adaptées aux problèmes déséquilibrés.

Métriques d'Évaluation

Étant donné le **déséquilibre des classes** dans le dataset, l'utilisation de métriques adaptées est essentielle.

Matrice de Confusion

Les performances sont analysées à partir des éléments suivants :
— TP : True Positives
— TN : True Negatives
— FP : False Positives
— FN : False Negatives

Accuracy

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Précision et Rappel

$$Precision = \frac{TP}{TP + FP} \qquad Recall = \frac{TP}{TP + FN}$$

F1-score

$$F1 = \frac{2 \times Precision \times Recall}{Precision + Recall}$$

Macro F1

$$F1_{macro} = \frac{1}{K} \sum_{i=1}^{K} F1_i$$

Le **F1-score macro** est particulièrement recommandé dans ce contexte, car il accorde une importance égale à toutes les classes, y compris les attaques rares.

Critères d'Évaluation du Challenge

L'évaluation globale des solutions repose sur une combinaison de critères scientifiques, techniques et communicationnels, visant à apprécier à la fois la performance des modèles proposés et la qualité de leur mise en œuvre.

— **Performance du modèle (40%)** Évaluation quantitative basée principalement sur le **F1-score (macro)** ainsi que sur des métriques complémentaires (Recall, Precision, ROC-AUC), adaptées aux données déséquilibrées.
— **Robustesse et généralisation (10%)** Capacité du modèle à maintenir des performances élevées sur des données non vues, tout en évitant le surapprentissage et en gérant efficacement la variabilité des attaques.
— **Qualité technique et reproductibilité (20%)** Clarté du code, structuration du pipeline expérimental, documentation des choix méthodologiques, et capacité à reproduire les résultats.
— **Innovation scientifique (10%)** Originalité des approches proposées (feature engineering avancé, modèles hybrides, techniques de rééquilibrage, etc.).

— **Présentation et communication (20%)** Clarté, rigueur et impact de la présentation finale, incluant la capacité à vulgariser des concepts techniques complexes.

Une attention particulière sera accordée aux approches capables de concilier performance, interprétabilité et robustesse, en cohérence avec les exigences des systèmes IDS réels.

Rendu Attendu et Modalités de Soumission

Chaque équipe devra fournir un ensemble complet de livrables permettant une évaluation rigoureuse et reproductible de la solution proposée.

Livrables obligatoires

— **Code source complet** Le code doit être **propre, structuré et documenté**, et publié sur une plateforme accessible (GitHub, GitLab, etc.). Il doit permettre une exécution reproductible (instructions d'installation incluses).
— **Rapport technique (documentation)** Un document détaillé décrivant :
  — la méthodologie adoptée
  — les choix de modèles et de features
  — les expérimentations réalisées
  — l'analyse des résultats
  Ce rapport fera l'objet d'une évaluation spécifique.
— **Vidéo de démonstration** Une courte vidéo présentant :
  — le fonctionnement du système
  — les résultats obtenus
  — une démonstration éventuelle
— **Présentation orale (Pitch)** Chaque équipe disposera de **6 minutes strictes** pour présenter son travail.
  — Toute minute supplémentaire entraînera une **pénalité directe sur la note**
  — Le respect du temps est considéré comme un critère d'évaluation

Contraintes de Soumission

— Tous les livrables doivent être déposés sur la plateforme officielle du challenge (Google Classroom)
— **Deadline stricte :** Les soumissions doivent être effectuées au plus tard à **09h59** le jour de la clôture.
— Tout retard entraînera une **pénalité** ou une **disqualification** selon la gravité.

Critères d'Évaluation des Livrables

— Qualité de la documentation (clarté, structure, rigueur scientifique)
— Reproductibilité des résultats
— Qualité de la démonstration
— Cohérence entre le modèle proposé et les résultats obtenus
— Capacité à analyser les limites de la solution

Les équipes sont encouragées à adopter une démarche scientifique rigoureuse, incluant l'analyse critique de leurs résultats et l'identification des limites de leur approche.

Considérations Avancées

Dans un contexte réel de cybersécurité, certaines erreurs sont plus critiques que d'autres :

— Les **faux négatifs** (attaques non détectées) doivent être minimisés
— Les **faux positifs** doivent être contrôlés pour éviter les alertes inutiles

Un bon modèle IDS ne se limite pas à maximiser l'accuracy, mais doit trouver un équilibre optimal entre détection des attaques et réduction des fausses alertes.

Comité du Jury

Le jury du challenge est composé d'enseignants-chercheurs spécialisés en Intelligence Artificielle et en sécurité. Il est chargé d'évaluer les solutions proposées selon les critères définis, en garantissant une appréciation rigoureuse, objective et équitable des projets.

— **Dr. Ing. Takwa Ben Aïcha Gader** Assistante contractuelle en informatique, spécialiste en IA, *Ambassadrice et instructrice NVIDIA certifiée en Deep Learning et IA générative.*
— **Dr. Ing. Ones Sidhom** Assistante contractuelle en informatique, spécialiste en IA, *Ambassadrice et instructrice NVIDIA certifiée en Deep Learning et IA générative*
— **Dr. Ing. Bessem Zaabar** Enseignant-chercheur et ingénieur en informatique, spécialisé en blockchain et sécurité.

Le jury s'appuie sur une expertise scientifique et pédagogique afin d'assurer une évaluation conforme aux standards académiques et aux exigences des applications réelles en cybersécurité.

10. Règlement du Hackathon

Le présent règlement définit les conditions de participation, les règles de conduite ainsi que les exigences techniques du mini-hackathon. Tout participant s'engage à le respecter intégralement.

Organisation Générale

— Durée du hackathon : **16 heures consécutives**
— Participation en équipes de **3 étudiants**
— Nombre total d'équipes : **4 équipes**
— Les participants doivent être présents durant toute la durée de l'événement

Règles Techniques

— L'utilisation des outils de Machine Learning et Deep Learning est autorisée (Python, Scikit-learn, TensorFlow, PyTorch, etc.)
— L'utilisation de ressources externes (documentation technique, bibliothèques, publications scientifiques) est autorisée. Néanmoins, les équipes doivent produire une solution **originale**, démontrant une compréhension approfondie des méthodes employées. Toute ressource utilisée doit être **correctement citée et référencée dans la documentation technique**, en indiquant explicitement son apport dans le développement de la solution.
— Le code doit être **fonctionnel, structuré et reproductible**
— Toute solution doit pouvoir être exécutée à partir des instructions fournies

Intégrité Académique et Plagiat

— Le **plagiat est strictement interdit**
— Toute copie partielle ou totale de solutions externes ou d'une autre équipe entraînera une **disqualification immédiate**
— Les participants doivent être en mesure d'expliquer et justifier leur travail
— L'utilisation d'outils d'IA est autorisée uniquement comme **outil d'assistance**, et non pour générer une solution complète sans compréhension

Comportement et Respect

- Les participants doivent adopter un comportement respectueux envers les autres équipes, les organisateurs et le jury
- Toute forme de **comportement inapproprié** (harcèlement, perturbation, non-respect des consignes) entraînera des sanctions
- L'esprit de collaboration et de fair-play est fortement encouragé

Soumission et Contraintes

- Les livrables doivent être soumis avant la deadline officielle
- Aucun retard ne sera accepté sans justification valable
- Les équipes doivent respecter les formats demandés (code, rapport, vidéo)

Sanctions

- Toute violation du règlement peut entraîner :
  - une pénalité sur la note
  - une disqualification
- Les décisions du jury et du comité d'organisation sont **finales et sans appel**

Ce hackathon vise à promouvoir l'excellence scientifique, l'intégrité académique et l'innovation, dans un cadre respectueux et professionnel.

11. Références

Références

[1] R. Lippmann et al., *Evaluating Intrusion Detection Systems : The 1998 DARPA Off-Line Intrusion Detection Evaluation*, DARPA, 2000.

[2] M. Tavallaee et al., *A Detailed Analysis of the KDD CUP 99 Data Set*, IEEE Symposium on Computational Intelligence, 2009.

[3] KDD Cup 1999 Dataset, `http://kdd.ics.uci.edu/databases/kddcup99/kddcup99.html`